

[서식 1] 학술대회 논문 발표

학술대회 논문 발표 마일리지 신청서

교과목명 (프로젝트명)	종합설계프로젝트1 (프로젝트명: 지도 & 위치 서비스 앱 개발)				
논문제목	바이브코딩을이용한대규모언어모델의AI모델구현성능비교연구				
발표학회	2025년 한국정보기술학회 추계종합학술대회				
발표일시 (장소)	2025.11.27.(목요일)(비대면 zoom 발표)				
논문 작성 참여 학생	소속(학과)	학위과정 (성별)	학번	성명	기여 점수 (총합 40점) ※소수점 불인정
	컴퓨터학부 (심화 컴퓨팅전공)	학사과정 (남)	2021114938	김재광	10
	컴퓨터학부 (글로벌 SW 전공)	학사과정 (남)	2021114928	최재혁	10
	컴퓨터학부 (심화 컴퓨팅전공)	학사과정 (여)	2022110627	백주은	10
	컴퓨터학부 (심화 컴퓨팅전공)	학사과정 (여)	2022113098	엄윤정	10

주1) 논문 발표 증빙자료 별첨 (예: 학술대회 프로시딩 등 논문 발표 관련 자료 등)

주2) 신청기한: 1학기 프로젝트(상반기), 2학기 프로젝트(신청 11월까지, 증빙 12월까지)

주3) 추가 증빙 논문에 SW중심대학 사사문구가 들어가 있어야 함

※ 사사문구: "본 연구는 과학기술정보통신부 및 정보통신기획평가원의 SW중심대학사업의 연구결과로 수행되었음"(2021-0-01082)"

바이브 코딩을 이용한 대규모 언어모델의

AI 모델 구현 성능 비교 연구

김재광, 백주은, 엄윤정, 최재혁, 백호기(교신저자), 안병준*

경북대학교, 엔앤피코리아*

691285@knu.ac.kr, jueun1827@knu.ac.kr, april138@knu.ac.kr,
chjh8800@knu.ac.kr, neloyou@knu.ac.kr, coolbrise@knu.ac.kr

Evaluating Large Language Models in AI Model Implementation via Vibe Coding

Jaegwang Kim, Joeeun Baek, Yoonjung Eom, Jaehyeok Choi, Hoki Baek, Byungjun An*

Kyungpook National University, N&P Korea Co., LTD*

요 약

본 연구는 AI 바이브 코딩(Vibe Coding)을 활용하여 대규모 언어모델(LLM)의 AI 모델 구현 및 선택 능력을 비교·분석한다. 220명의 빵 취향 설문 데이터를 활용하여 ChatGPT, Gemini, Claude에 동일한 데이터 및 프롬프트를 제공하고, 사용자의 선호 빵을 예측하는 모델을 생성하도록 요청한다. 첫 번째 실험에서는 각 LLM이 자유롭게 모델을 선택해 구현한 경우의 정확도를 평가하고, 두 번째 실험에서는 같은 AI 모델들을 지정하여 구현 정확도를 비교한다. 본 연구를 통해 LLM의 모델 선택 능력, 코드 구현 성능, 그리고 프롬프트 기반 개발의 효율성을 검증한다.

Key words

Machine learning, SVM, Logistic Regression, Random Forest, LLM, Vibe coding

1. 서 론

최근 몇 년간 대규모 언어모델(Large Language Model, LLM)의 급격한 발전은 인공지능의 활용 범위를 확장시켰다. 특히 고성능 LLM들은 단순한 대

화형 시스템을 넘어, 코드 작성, 디버깅, 문서화 등 소프트웨어 전반에 활용되고 있다. 이러한 변화는 LLM과의 상호작용을 통해 코드 생성을 조율하는, 바이브 코딩(Vibe Coding)이라 불리는 새로운 접근을 촉진한다. 바이브 코딩은 기술적 장벽을 낮춰,

*소속, Email, **소속, Email(교신저자표시), ...

※ 지원기관표기(사사표기)

전문 지식이 부족한 비전문가도 LLM을 활용해 완성도 높은 서비스를 신속히 구현할 수 있게 한다. 그 결과 1인 개발자나 소규모 스타트업 창업자들이 LLM을 활용하여 아이디어를 실제 서비스로 구현하는 바이브 코딩 사례가 급격히 증가하고 있으며, 이는 LLM이 실질적 생산성을 제공하는 단계에 도달했음을 보여준다. 본 논문에서는 고성능 LLM 중 Chat GPT, Claude, Gemini에 동일한 프롬프트를 제시하고, 생성된 AI 모델 코드의 성능과 특징을 비교·분석한다. 특히, AI 모델을 선택 및 코드 구현 능력을 중심으로 평가하여, 각 LLM이 실제 개발 환경에서 갖는 실용적 가치를 탐구하고자 하는 것이 본 연구의 목적이다.

II. 문헌 연구 및 연구 배경

2.1 LLM 발전 및 범용화

초기의 LLM은 주로 문장 생성이나 분류 등 제한된 자연어 처리(NLP) 작업에 특화되어 있었다. 이후 매개변수 수가 증가하고 범용적 언어 이해 및 생성 능력이 향상되면서 ChatGPT, Claude, Gemini와 같은 고성능 LLM 시대로 전환되었다. 특히 멀티모달(MultiModal) 이해·추론 능력, 장기 문맥 이해, 코드 생성 능력이 비약적으로 향상되면서 LLM은 단순한 언어 처리 도구를 넘어, 인간의 사고 과정을 보조하거나 자동화하는 지식 생산 플랫폼으로 진화하였다.

2.2 바이브 코딩 활용 사례

「Vibe coding: programming through conversation with artificial intelligence」 [2]에서는 인간과 AI 간의 대화 기반 프로그래밍 패러다임인 바이브 코딩 개념을 제시하였다. 해당 연구에 따르면, 바이브 코딩은 프로그래머가 직접 코드 작성에서 벗어나 LLM과 상호작용하여 목표를 탐색하고 결과를 반복 조정하는 새로운 개발 방식이다. 이 과정에서 전문성은 프롬프트 설계, 맥락 관리, 코드 검증 등으로 재분배되며, AI를 매개로 한 협업적 창작 모델로서 확장 가능성을 가진다. 「바이브 코딩 중국어 교육

게임 웹앱 제작 연구」에서 바이브 코딩을 활용하여 비전문가도 고품질 교육용 웹앱 콘텐츠를 제작할 수 있음을 보여주었다 [1]. 그리고 클라우드 기반 환경에서 퀴즈 콘텐츠 생성 효율성과 한계를 분석하며 다양한 프롬프트 설계를 통해 웹앱을 자동 생성하는 사례를 제시하였다. 이를 통해 바이브 코딩이 노코드(No-code), 즉 코딩 지식 없이도 개발이 가능한 방식의 확장 형태로서 교육자가 능동적 콘텐츠 제작자로 전환될 수 있음을 강조한다. 바이브 코딩은 코딩을 넘어, 과학적 아이디어 생성, 답러닝 모델 역설계 등 다양한 분야에서 활용 가능성이 보고되고 있다. 본 연구는 이러한 선행 연구를 바탕으로, LLM의 실제 데이터 기반 모델링과 코드 구현 역량을 실험적으로 검증하여 평가하고자 한다.

III. 실험 설계

3.1 데이터 세트 및 학습 방법

본 실험의 데이터는 익명 온라인 설문을 통해 수집하였다. 대한민국 거주 10대부터 40대를 대상으로 온라인 공개 링크를 배포해 응답자를 모집하였다. 총 유효 응답은 220개이며, 데이터 세트는 15개 변수로 구성된다. (1) 인구통계 2개 (성별, 연령대), (2) 뽕 선호 특성 10문항 (1 = 전혀 선호하지 않음 ~ 5 = 매우 선호함), (3) 사전 정의된 9개 뽕 중 응답자가 선택한 선호 뽕 상위 3개(Top1 - Top3). 220개의 표본 수는 예측 모델 학습에 다소 제한적인 규모로, 단순한 훈련-검증 분할 시 과적합(overfitting)과 불안정한 성능 평가가 발생할 수 있다. 데이터양을 늘리기 위한 증강(augmentation) 기법도 고려하였으나, 본 데이터는 특성 왜곡에 민감하고 원본 분포의 왜곡 위험이 커 증강을 적용하지 않았다. 대신, 제한된 표본 내 모델의 일반화 성능을 높이기 위해 교차 검증(cross validation)을 채택하였다. 본 실험에서는 5-Fold 교차 검증을 사용하였다. 전체 데이터를 무작위의 5개의 fold로 분할한 후, 회차마다 한 개의 fold를 검증 세트로, 나머지 4개를 학습 세트로 사용하였다. 지나치게 많은 fold는 학습 데이터가 과도하게 줄어드는 반면, 적은 fold는 검증의 다양성이 부족하다. 따라서 5-fold 방식을 통해 데이터

손실 최소화와 검증 안정성 간의 균형점을 확보하였다. 각 회차의 정확도를 계산하고, 평균 정확도를 최종 모델 성능으로 평가하였다.

3.2 목표 정의

본 실험의 목표는 응답자의 취향 응답으로부터 선호 빵을 예측하는 동일한 다중 분류 문제에 대해, 서로 다른 대규모 언어모델(LLM)이 생성한 코드의 성능을 비교·평가하는 것이다. 이를 위해 동일한 응답 데이터 세트와 동일한 작업 지시 프롬프트를 각 LLM에 제시하고, 각 LLM이 작성한 분류 모델 코드를 변경 없이 시행하였다. 그 결과로 얻어진 모델의 예측 성능(accuracy)을 측정·비교함으로써 어떤 LLM이 더 적절한 모델링 선택을 수행하고 더 높은 예측 성능을 갖는 코드를 생성하는지를 평가하였다.

3.3 프롬프트 설계

프롬프트는 목표, 데이터 설명, 요구 사항 총 세 가지 요소로 구성하였다.

- 목표: “응답자의 입력(성별, 나이, 10개 취향 문항)으로부터 선호 빵 1종을 예측하라.”
- 데이터 설명: 각 컬럼 정의, 값 범위, 목표 레이블 (Top3 집합), 평가 규칙(단일 예측이 Top 3에 포함되면 정답 처리)
- 요구 사항: K-fold cross validation 적용, 학습 • 검증 데이터의 분리, 테스트 평가 및 정확도 보고

프롬프트 작성 시에는 명확한 언어와 모호한 언어를 병행하여 사용하였다. 명확한 언어는 데이터 분할, 평가 지표 등 오관이 치명적인 구간에서 사용하여 기본적인 성능과 재현성을 확보하였으며, 모호한 언어는 모델 선택 및 하이퍼파라미터 탐색과 같은 창의적 판단이 필요한 구간에 사용하여 LLM의 자율적 판단력을 유도하였다.

3.4 평가지표

본 실험에서는 LLM이 생성한 AI 모델의 예측 정확도 및 판단 적합성을 평가하기 위해, 일반적인 정확도(accuracy) 대신 사용자 정의 평가지표 (Custom Top-1 Accuracy)를 적용하였다. Custom

Top-1 Accuracy(이하 Top-1 Accuracy)는 모델이 예측한 단일 결과가 실제 응답자의 선호 빵 상위 3개 (Top3) 중 하나와 일치하면 이를 정확한 예측으로 간주하는 방식이다.

이 지표는 본 실험의 예측 과제가 단일 정답 (classification)보다 부분적 일치(partial match)를 허용하는 선호 예측(preference prediction) 문제의 특성을 반영하기 위함이다.

이를 통해 단순한 분류 정확뿐 아니라, 모델이 사용자의 실제 선호 경향을 얼마나 포착하고 있는지 평가할 수 있다. 또한 동일한 데이터 세트와 조건에서 LLM 별로 생성된 모델의 Top-1 Accuracy를 비교함으로써, 각 LLM이 보여주는 모델 선택 능력(판단력), 구현 정확성(구현력)의 차이를 정량적으로 검증하였다.

3.5 실험1 : 자유 모델 선택 능력 평가 - 판단력

실험 1에서는 특정 알고리즘을 지시 없이 모호한 언어로 프롬프트를 설계하여, 각 LLM이 주어진 데이터 규모, 특성, 변수 수를 고려하여 적절한 학습 모델을 자율적으로 판단 • 선택하는 능력을 평가하였다. 다만 프로토콜 차이로 인한 성능 편차를 최소화하고 모델 선택 판단력만을 평가하기 위해, 다음 절차는 프롬프트에 명확한 언어로 지시하였다: (i) 데이터 전처리 포함 (ii) 80:20 학습/테스트 데이터 분할 (iii) k-fold 교차 검증 사용 (iv) Randomized Search를 통한 하이퍼파라미터 탐색 (v) Top-1 Accuracy 최종 보고. 최종적으로 LLM의 모델링 판단력을 Top-1 Accuracy를 통해 정량적으로 평가하였다.

3.6 실험2 : 지정 모델 구현 정확성 평가 - 구현력

실험 2는 LLM의 지시 해석력과 코드 구현 정확성을 평가하기 위한 것이다. 실험 1의 프로토콜을 동일하게 유지하되, 각 LLM에게 세 가지 AI 모델을 명확한 언어로 지정하여 구현하도록 유도하였다: (i) Random Forest, (ii) Support Vector Machine(SVM),

(iii) Logistic Regression.

각 모델별 코드가 요구사항을 정확히 충족하는지를 검토하고 생성된 코드의 실행 결과를 통해 모델별 Top-1 Accuracy를 측정하였다. LLM이 지시를 정확히 해석하고, 주어진 명세를 충실히 구현하는 코드 생성 정확도 및 안정성을 평가하였다.

IV. 실험 결과 및 논의(연구 결과)

4.1 실험1 : 자유 모델 선택 능력 평가 - 판단력

실험1에서는 각 LLM이 동일한 데이터와 목표를 기반으로 스스로 최적의 머신러닝 모델을 선택하여 구현하도록 하였다. 다음 Table 1은 LLM 별 모델 선택 유형과 그에 따른 Top-1 Accuracy를 비교한 결과이다.

	선택한 모델	Top-1 Accuracy
ChatGPT (GPT-5)	Logistic Regression (OVR)	61.36%
Claude (Sonnet 4.5)	Random Forest Classifier	54.55%
Gemini (Gemini 2.5 Pro)	Random Forest Classifier	56.82%

[Table 1] LLM별 최적모델 및 Top-1 Accuracy 비교

ChatGPT는 세 모델 중 Logistic Regression(OVR, One-vs-Rest 방식)을 선택하였으며, 61.36%의 Top-1 Accuracy로 가장 높은 성능을 보였다. 반면, Claude와 Gemini는 공통으로 Random Forest Classifier를 선택하였으나, 각각 54.55%, 56.82%로 ChatGPT에 비해 다소 낮은 성능을 보였다.

이러한 차이는 LLM의 모델 선택 전략과 데이터 해석 방식의 차이에서 기인한다. ChatGPT는 선형 분류 기반의 단순 모델을 선택함으로써, 소규모 데이터(n=220)와 다차원 입력 관계를 효율적으로 일반화했다. 반면 Claude와 Gemini는 비선형적 패턴 탐색에 집중하였으나, 학습 데이터의 크기 제한을 고려하지 못하여 과적합으로 이어졌다.

4.2 실험2 : 지정 모델 구현 정확성 평가 - 구현력

실험 2에서는 각 LLM이 세 가지 머신러닝 알고리즘(Random Forest, SVM, Logistic Regression)을 모두 구현하도록 동일한 프롬프트를 제공하였다. 이를 통해 LLM이 동일한 과제를 수행할 때, 코드 구현의 정확성과 모델 이해도를 검증하고자 하였다. Table 2는 각 LLM 별로 구현한 세 가지 모델의 Top-1 Accuracy를 비교한 결과이다.

	Random Forest	SVM	Logistic Regression
ChatGPT (GPT-5)	59.09%	54.55%	56.82%
Claude (Sonnet 4.5)	50%	61.36%	54.55%
Gemini (Gemini 2.5 Pro)	61.36%	65.91%	65.91%

[Table 2] LLM별 모델 구현 Top-1 Accuracy 비교

실험 결과, 세 LLM 모두 Logistic Regression 모델에서 가장 높은 정확도를 보였으며, Claude와 Gemini의 Logistic Regression에서 동일하게 65.91%를 기록하였다. ChatGPT 역시 Logistic Regression에서 61.36%를 기록하며 세 모델 중 가장 우수한 성능을 보였다.

반면, SVM의 경우 ChatGPT는 50%로 가장 낮은 정확도를 보였으나, Claude는 61.36%로 비교적 안정적인 결과를 나타냈다. Random Forest는 모든 LLM에서 중간 수준의 정확도를 보였으며(54.55% ~ 59.09%), 모델 복잡도에 비해 성능 개선 폭은 크지 않았다. 특히 Claude와 Gemini는 회귀 기반 모델(Logistic Regression)에 대해 높은 일관성과 정확도를 보였다.

V. 결 론

본 연구에서는 Chat GPT, Claude, Gemini 세 가지 LLM을 대상으로 동일한 데이터와 프롬프트 조건에서 AI 모델 구현 실험을 수행하였다. 첫 번째 실험에서는 각 모델이 스스로 최적의 알고리즘을 선택하도록 하였고, 두 번째 실험에서는 동일한 세 가지 알고리즘(Random Forest, SVM, Logistic Regression)을 직접 구현하도록 하였다.

첫 번째 실험의 결과, ChatGPT는 데이터의 특성과 규모를 고려한 가장 합리적인 모델 선택을 수행

한 반면, Claude와 Gemini는 과적합 위험성이 높은 모델을 선택함으로써 상대적으로 낮은 예측 정확도를 보였다. 이는 LLM이 문제 구조를 해석하고 적절한 알고리즘을 선택하는 판단력에서도 유의미한 차이가 존재한다.

두 번째 실험의 결과, Claude와 Gemini이 수학적 모델링과 회귀 계수 계산 로직을 명확히 이해하는 경향을 보였다.

즉, ChatGPT는 모델 선택 단계에서 가장 높은 예측 정확도를 보였으며, Claude와 Gemini는 지정된 모델 구현에서 우수한 성능을 보였다.

모든 실험을 통해 LLM이 단순 코드 생성을 넘어, 모델링 단계의 판단력과 구현 능력을 함께 갖추고 있음을 시사한다. 각 LLM이 서로 다른 강점을 보인다는 점에서, 향후 LLM의 역할은 단일 개발 도구가 아닌 강점에 따라 선택되는 AI 개발 파트너로 확장될 가능성을 보여준다.

본 연구는 LLM이 인간 개발자의 의사결정 일부를 대체할 수 있는 가능성을 실험적으로 확인하였으며, 향후 자율적 AI 모델링 및 자동화된 데이터 분석 시스템 개발에 기여할 수 있을 것으로 기대된다.

참 고 문 헌

- [1] 박정원, "바이브 코딩 중국어 교육 게임 웹앱 제작 연구", September 2025
- [2] Advait Sarkar and Ian Drosos, "Vibe coding: programming through conversation with artificial intelligence", October 2025.

“본 연구는 과학기술정보통신부 및 정보통신기획평가원의 SW중심대학사업의 연구결과로 수행되었음” (2021-0-01082)