

EDA, 원핫인코딩, 위클러인 유사도, MSE, 회귀분석, K-NN, K-fold, K-MN, 로버스트 회귀 분석, 시그모이드 함수

1. 리스트와 넘파이 (NumPy)

리스트 vs 넘파이

`list * 2 = [1 2 1 2] / numpy * 2 = [2 4]`

리스트는 2차원 X

2. 판다스 (Pandas)

`set_index['도시'], inplace = True`: 도시를 index로 설정(inplace = True) 해야지 원본이 바뀐다.

데이터 읽기: `df.연도, df['연도']`, 행 슬라이싱 (0:2).

`drop(['연도'],1)`: 연도 없애기

3. 데이터 분석 이유 및 용어

분석 이유: 설명, 예측, 추천.

입력값 (X): 독립변수, 피쳐 (예: 몸무게, 나이).

결과값 (Y): 종속변수, 라벨, 정답, 타겟 (예: 고혈압).

4. 데이터 분석 유형

지도 학습: 입력과 결과가 모두 존재. 예측 후 시간이 지나면 정답 확인 가능.

회기 - 연속적인 값 예측(온도, 주가..) $y = ax + b$

분류 - 어떤 그룹에 속하는지 구별 (T/F, 등급) $ax + by + c > 0$

비지도 학습: 입력만 존재, 결과 X 패턴이나 특성 발견
클러스터링: 비슷한 데이터를 집단으로 묶음(K-means..)
강화학습: 정답은 있지만 알려주지 않고 보상으로 방향성 제공

5. 탐색적 분석(EDA)

수집한 데이터의 전체적인 특성을 분석

이상치 (Outlier): IQR (Q3 - Q1)을 기준으로 1.5배 떨어진 하한/상한 펜스 밖에 있는 데이터.

6. 데이터 전처리 (Data Preprocessing)

데이터 전처리

데이터 분석 성능 향상, 형태 변형

결측값 처리: `dropNA()` - 버리기, `fillna()` - 대체, 분석 단계로 넘기기

오류값 처리: 버리거나 대체

이상치 처리: IQR 계산 기준

범주형 변수 처리:

원핫 인코딩: 한 개만 1, 나머지는 0 (`get_dummies()`)

스케일링: 단위/기준이 다른 데이터를 동일 기준으로 조정

표준 스케일링: 평균 0, 표준편차 1로 조정.

최소-최대 스케일링: 최소 0, 최대 1로 조정.

7. 머신러닝 학습 과정

데이터 분리: 훈련 데이터(학습), 검증 데이터(모델 검증), 테스트 데이터(미지 데이터 최종 평가).

최근에는 훈련/검증 데이터로 바로 진행하는 경우가 많음.

모델: 수학적 (구조와 파라미터).

학습 과정: 모델 학습 → 예측 → 손실 확인 → 손실 감소 방향으로 반복 → 모델 확정 → 성능 평가.

8. 군집화 (Clustering) 상제

목적: 비슷한 특성을 가진 데이터 집단으로 묶기 (비지도 학습).

유사도 측정:

유클리드 거리 (Euclidean Distance): 절대적 거리값.

코사인 유사도 (Cosine Similarity): 방향 유사성 (텍스트 분석 등에 활용).

자카드 유사도 (Jaccard Similarity): 공통 부분을 고려한 상대적 유사성 (영화/책/음악 추천에 활용).

클러스터의 수 (K): 그룹의 개수 설정이 중요. (K값이 너무 작거나 크면 문제 발생).

군집화 알고리즘:

$K = \text{클러스터의 수}$

K-평균 (K-Means): 임의의 중심점 설정 → 거리 측정 → 중심점 이동 반복 → 최적의 평균값 찾으면 종료.

DB스캔 (DBSCAN): 밀도 기반 클러스터링 (달 모양 데이터 등에 적합).

9. 선형 회기 및 분류

선형 회기: $y = ax + b$ (기울기 A, Y절편 B 추출).

선형 분류: $ax + by + c > 0$ (결정 경계선).

10. 손실 함수 (Loss Function)

회기: 평균 자승 오차 (**MSE**): $(\text{예측값} - \text{실제값})^2$ 의 평균.

파라미터(가계 학습), 하이퍼파라미터(사람 선택).

분류: **크로스 엔트로피** (Cross-Entropy):

정확도를 손실 함수로 사용할 때 비대칭 문제 발생 (예: 남녀 오분류).

확률을 고려하여 계산.

11. 경사하강법 (Gradient Descent)

경사하강법: 모든 데이터에 대해 기울기 계산, 최솟값(기울기 0)을 찾음. 정확성 높지만 수행 시간 김.

확률적 경사하강법: 랜덤으로 데이터를 추출하여 기울기 계산. 속도 빠르지만 노이즈 존재, 모델 성능은 경사하강법과 유사.

12. 데이터 분리 및 교차 검증

훈련/검증/테스트 데이터 분리: `train_test_split()` 함수

비교 → 동일 데이터

활용.

random_state로 고정된 랜덤 값 설정하여 동일한 데이터 분리.

분류 회기 하이

K-폴드 교차 검증 (K-Fold Cross-Validation):

데이터를 여러 등분(기본 5개)으로 나누어 모든 데이터가 훈련과 검증에 모두 사용되도록 함.

데이터가 한쪽으로 쏠리는 현상 방지.

13. KNN (K-Nearest Neighbors)

개념: 최근접 이웃 알고리즘. 가장 가까운 데이터를 하나의 그룹으로 묶음.

K값 설정이 중요.

14. 과소적합과 과대적합

과소적합: 데이터 부족으로 모델 생성 어려움.

과대적합: 훈련 데이터에 너무 충실하여 일반화 성능 떨어짐.

훈련 데이터는 성능 좋으나 검증 데이터는 성능 저하.

해결: 규제 (릿지, 라쏘) 적용.

15. 머신러닝 알고리즘 흐름 ^{설명}

데이터 분리: train_test_split.

모델 생성 및 훈련: model = LogisticRegression(),
model.fit(X_train, Y_train).

예측: model.predict(X_test).

성능 평가: model.score(X_test, Y_test) 또는
accuracy_score().

16. 로지스틱 회기 분석 (Logistic Regression)

목적: 결과값이 0 또는 1인 이진 분류 예측 (예: 합격/불합격, 신용도 등).

시그모이드 함수: S자 곡선 형태를 그림. 기울기에 따라 곡선의 가파름 정도 변화.

함수