

M3(머신러닝) 시험 대비

과대적합(Overfitting)

모델이 훈련데이터에서만 잘 동작하도록 훈련되어, 새로운 데이터에 대해서는 오히려 잘 동작하지 못하는 것 (학습데이터에 너무 민감하게 반응)

손실함수(Loss Function)

분류 문제에서 주로 사용되는 손실함수=크로스 엔트로피

배치 크기

Q. 배치 크기 구하기

1000개 데이터가 있을 때, 50개씩 묶어서 여러 계산을 누적 시키고 50개 끝난 뒤에 한 번 학습 함. 이때 배치 사이즈 = 50

경사 하강법

현재 위치에서 기울기(미분값)에 비례하여 반대방향으로 이동하면서 학습하는 최적화 방법

경사 하강법 학습률(서술)

학습률이 작을 때: 수렴하는데 오래 걸리지만, 최저점에 도달했을 때 흔들림 없이 안정적인 값을 얻을 수 있다.

학습률이 클 때: 학습하는 속도는 빠르나 자칫하면 최저점으로 수렴하지 못하고 발산하거나 수렴하더라도 흔들리는 오차가 남아있을 수 있다.

F1 점수 계산

$$F1 = \frac{2ab}{a+b}$$

KNN 알고리즘

주어진 샘플의 특성 값과 가장 가까운 특성을 가진 이웃(neighbor)을 k개 선택

선택된 이웃들 레이블의 평균치로 이 샘플이 속할 category를 예측

결정트리 알고리즘

각 특성을 독립적으로 하나씩 검토하여 분류 작업을 수행

동작 한 번에 한 특성을 따져보는 방법

sepal length 기준값에 따라 T/F 나뉘서 내려감.

Gini 계수 구하는 방법

$$Gini = 1 - \left[\left(\frac{a}{n} \right)^2 + \left(\frac{b}{n} \right)^2 \dots \right]$$

랜덤 포레스트

결정 트리의 성능을 개선한 것으로써

비교적 간단한 구조의 결정트리들을 수십~수백개를 랜덤하게 만들고 각 결정트리의 동작 결과를 종합하여 판정하는 모델

SVM(서술)

선형 분류할 때 각 클래스에 가장 가까운 서포트 벡터를 찾고, 이 서포트 벡터를 수직 이등분하면서 마진을 최대화하는 선형 분류기

텍스트 분석 기본 용어

텍스트 분석 시 사용되는

최소 단위 = 토큰

전체 문서 집합 = 말뭉치(corpus)

[코드 관련]

cross_val_score()

교차검증을 수행하는데 사용하는 함수

```
from sklearn.tree import DecisionTreeClassifier
```

-결정 트리 알고리즘 import

```
clf = DecisionTreeClassifier(max_depth = 2)
```

```
clf.fit(x,y)
```

-결정 트리 알고리즘에 대해서 depth가 2번 내려가게하고 실제 x,y 데이터를 훈련 데이터로 줘서 결정 트리를 학습시킨다.

```
sc = StandardScaler()
```

```
x_all = sc.fit_transform(x_all)
```

-데이터를 표준 정규화해준다